

PS3 - Equipo 03

Catalina Leal Rojas, Lucas Daniel Carrillo Aguirre, Lucas Eduardo Veras Costa,
Mateo Hernández

24 de noviembre de 2025

El link del repositorio es: https://github.com/cataleal/PS3_Equipo3

1. Introducción

El mercado de vivienda ha sido históricamente uno de los sectores más observados tanto por los responsables de política pública como por la ciudadanía en general. Su relevancia quedó particularmente evidenciada durante la crisis del *subprime* en Estados Unidos, cuando la sobrevaloración sistemática de los precios llevó a un colapso financiero con efectos globales. Además del rol macroeconómico de la vivienda como activo y como garantía crediticia, el monitoreo de precios es fundamental para la gestión de riesgos bancarios, la planeación urbana y las decisiones de inversión de hogares y empresas. En respuesta a estos desafíos, entidades financieras y plataformas inmobiliarias utilizan cada vez más modelos automatizados de valoración (*Automated Valuation Models*, AVM) para estimar el precio de propiedades de manera rápida, estandarizada y a bajo costo.

Sin embargo, el caso de Zillow ([Corkery and Gelles, 2021](#)) ilustra los riesgos asociados al uso inadecuado de estos sistemas. El fracaso de su modelo de compra automatizada —que sobreestimó de manera sistemática los valores de mercado— resultó en pérdidas superiores a 500 millones de dólares y en una reducción sustancial de su fuerza laboral. Este ejemplo ha reforzado la necesidad de modelos predictivos más robustos, capaces de capturar adecuadamente las complejidades del mercado inmobiliario y de generalizar de forma confiable a nuevos datos. En particular, los AVM basados exclusivamente en métodos lineales se enfrentan a limitaciones importantes derivadas de supuestos de linealidad, problemas de variables omitidas y la presencia de datos faltantes o mal medidos.

En los últimos años, los algoritmos de aprendizaje de máquina (ML) han surgido como una alternativa poderosa para tareas de valoración masiva de inmuebles. Modelos como árboles de decisión, Random Forest, Gradient Boosting, redes neuronales y métodos híbridos tipo *Super-Learner* permiten modelar relaciones altamente no lineales y capturar interacciones complejas entre atributos estructurales, amenidades urbanas y características del entorno construido. Estudios recientes como [Mora-Garcia et al. \(2022\)](#), [Ho et al. \(2020\)](#), [Hjort et al. \(2022\)](#) y [Baur et al. \(2023\)](#) encuentran que estos algoritmos superan consistentemente el rendimiento de los modelos hedónicos tradicionales, especialmente cuando se trabaja con grandes volúmenes de microdatos georreferenciados y entornos urbanos heterogéneos.

Siguiendo esta literatura, este estudio desarrolla un conjunto de modelos predictivos para estimar los precios de vivienda en Bogotá como parte del desafío planteado en el Problem Set 3 del curso MECA-4107. El contexto específico del barrio Chapinero —caracterizado por una enorme heterogeneidad en tipos de vivienda, usos de suelo y accesibilidad a múltiples servicios urbanos— lo convierte en un entorno especialmente adecuado para evaluar la capacidad de los algoritmos de ML de capturar no linealidades y patrones espacialmente estructurados. Para ello se construyó una base de datos enriquecida que combina información estructural de Properati con variables extraídas de OpenStreetMap, medidas de accesibilidad, atributos textuales de títulos y descripciones, y otros indicadores urbanos. Los datos que utilizamos ofrecen una visión clara y detallada del mercado inmobiliario del norte de Bogotá, combinando características estructurales, amenidades, precios y ubicación que permiten capturar adecuadamente la diversidad de viviendas en la ciudad.

La estrategia empírica contempla la comparación sistemática de ocho enfoques distintos: regresión lineal, Lasso, Elastic Net, CART, Random Forest, modelos de *boosting*, redes neuronales y *Super-Learner*. En algunos de ellos se implementa validación cruzada espacial —mediante partición geográfica del dominio de Bogotá— con el fin de evaluar de forma más realista la capacidad de generalización espacial del modelo, mientras que otros emplean validación cruzada convencional. Esta comparación permite analizar de manera rigurosa las diferencias en desempeño entre métodos, así como identificar qué algoritmos son más robustos frente a la heterogeneidad espacial y la presencia de patrones locales.

Entre todos los modelos evaluados, la red neuronal de una sola capa con 20 neuronas —entrenada sin tuning y validada de forma tradicional— obtuvo el mejor desempeño en la predicción del precio de la vivienda. Este resultado es especialmente notable dado que superó métodos más complejos como Random Forest, XGBoost y diversos ensamblajes de SuperLearner, lo que sugiere que una estructura relativamente simple puede capturar de manera efectiva las relaciones no lineales presentes en el mercado inmobiliario analizado.

Por otro lado, la validación cruzada espacial mostró que los modelos rinden peor cuando se rompe la cercanía geográfica entre entrenamiento y prueba, evidenciando que su capacidad de generalización en Chapinero depende fuertemente de patrones locales del mercado inmobiliario.

Finalmente, este documento se organiza de la siguiente manera: la siguiente sección describe los datos utilizados; posteriormente se presentan los modelos empleados y su proceso de estimación; y por último se ofrece una breve conclusión.

2. Datos

2.1. Fuente

Los datos utilizados en este trabajo fueron extraídos de la plataforma Properati, la cual funciona como un portal de publicación de bienes inmuebles para posibles compradores o arrendatarios. La base completa, obtenida a través de la competencia de Kaggle, contiene información para 48.930 viviendas ubicadas en Bogotá, Colombia, con un total de 17 variables que incluyen tamaño, características habitacionales, ubicación, precio y una breve descripción del inmueble.

Esta base se encuentra dividida en dos subconjuntos: *train* y *test*. El conjunto de *train* contiene información de 38.644 viviendas en toda la ciudad, incluyendo su precio, mientras que el conjunto de *test* incluye 10.286 observaciones ubicadas exclusivamente en la localidad de Chapinero, pero sin información sobre el precio, que constituye la variable objetivo.

Adicionalmente, se incorporó información geoespacial para complementar las características de los inmuebles, incluyendo medidas de cercanía a puntos de referencia clave en términos de acceso a servicios de salud, cultura, transporte y comercio, así como características socioeconómicas del entorno (estrato, avalúo catastral, criminalidad y densidad de establecimientos comerciales). Esta información proviene de la plataforma *Datos Abiertos Bogotá*, un repositorio distrital de acceso público.

2.2. Procesamiento

2.2.1. Variables de texto

Se construyó inicialmente una variable que unifica el título y la descripción de cada aviso, de modo que toda la información relevante sobre el inmueble quedara contenida en un solo campo. Sobre este texto unificado se aplicó un proceso de limpieza consistente en transformar a minúsculas, eliminar acentos, signos de puntuación y espacios redundantes, con el objetivo de estandarizar las expresiones clave y facilitar su detección.

Posteriormente, se revisaron manualmente las palabras y expresiones más frecuentes en las descripciones, con el fin de identificar información asociada al tamaño, número de habitaciones, condiciones de seguridad y comodidades adicionales. Con base en esta revisión se construyó un diccionario de 33 variables derivadas del texto: 30 dicotómicas que indican la presencia o ausencia de ciertos *amenities* (cocina integral, balcón, terraza, ascensor, gimnasio, zona infantil, *rooftop*, entre otros) y

3 numéricas asociadas a área, número de parqueaderos y número de baños mencionados en el aviso. Para las variables dicotómicas, la ausencia de la palabra clave se interpretó como valor cero. En particular, para parqueaderos se asumió que la ausencia de la mención implica que el inmueble no dispone de ellos.

Las variables numéricas extraídas del texto se obtuvieron mediante expresiones regulares que identifican números inmediatamente anteriores a palabras clave como “baño(s)”, “parqueadero(s)”, “garaje(s)” o expresiones de área como “m2”, “mts2” o “metros cuadrados”. Cuando en un mismo aviso aparecían múltiples menciones, estas se sumaron para obtener el total reportado.

A partir de estas variables textuales se imputaron datos faltantes en área y número de baños. Los valores presentes en la base original se mantuvieron sin modificaciones y únicamente se reemplazaron los faltantes cuando existía una estimación consistente derivada del texto. Para los casos aún faltantes, se implementó un esquema adicional de imputación basado en promedios condicionales según combinaciones de barrio (o UPZ), número de habitaciones, número de baños, estrato socioeconómico y tipo de propiedad. Para evitar una fragmentación excesiva se agruparon las áreas en intervalos de 10 metros cuadrados.

En síntesis, el módulo de texto permitió incorporar características cualitativas usualmente ausentes en bases administrativas, y mejorar notablemente la medición de variables clave como área y número de baños, que son fundamentales para explicar el precio de la vivienda.

2.2.2. Variables espaciales

El segundo bloque comprende las características espaciales y del entorno inmediato. Partiendo de la base ya enriquecida con variables textuales, se leyeron los conjuntos *train* y *test* en formato RDS y se unificaron en un solo objeto. A partir de las coordenadas de longitud y latitud, se construyó un objeto espacial de clase `sf` usando el sistema WGS 84 (EPSG 4326), lo que permitió vincular correctamente las capas geográficas externas.

En primer lugar, se incorporó información administrativa básica. Utilizando la capa de localidades del Distrito, re proyectada a EPSG 4326, se asignó a cada inmueble su localidad mediante una unión espacial. De manera similar, se asignó el sector censal correspondiente, permitiendo un nivel adicional de desagregación. En segundo lugar, se integraron capas temáticas de Datos Abiertos Bogotá. A nivel de localidad se agregaron indicadores de espacio público efectivo, mientras que a nivel de UPZ se agregó el indicador de espacio público efectivo por hectárea. También se incluyó el número total de luminarias por UPZ como proxy de iluminación y presencia de infraestructura.

Para capturar accesibilidad a equipamientos urbanos se utilizaron las capas de bibliotecas, museos, colegios oficiales y estaciones de TransMilenio. Con estas capas se calcularon distancias geodésicas entre cada vivienda y el equipamiento más cercano, generando variables continuas interpretables como medidas de accesibilidad.

En el ámbito socioeconómico y fiscal, se incorporó información de recaudo predial y estratificación, asignando a cada inmueble el valor del polígono correspondiente y el estrato de la manzana más cercana, respectivamente. En seguridad, se integró la capa de delitos por localidad. Tras depurar las variables y renombrarlas para mantener consistencia, se calcularon promedios para los años 2019, 2020 y 2022 para cada tipo de delito (homicidios, lesiones personales, hurtos a personas, vehículos, comercio, residencias, bicicletas, celulares, delitos sexuales y violencia intrafamiliar).

La inclusión de información geoespacial es fundamental, pues permite capturar dimensiones del

valor de la vivienda que no pueden inferirse únicamente a partir de sus atributos físicos. En mercados urbanos como Chapinero, factores como accesibilidad, calidad del entorno, seguridad, oferta de servicios y estructura socioeconómica influyen decisivamente en los precios y, por tanto, deben incorporarse en modelos de predicción.

2.3. Estadísticas descriptivas y selección final de variables

Aunque todas las variables extraídas constituyen potenciales predictores del precio de la vivienda, utilizarlas simultáneamente puede incrementar el riesgo de *overfitting* y los costos computacionales, particularmente en modelos no lineales. Por ello, se redujo el conjunto de predictores a 17 variables mediante un modelo Lasso, cuya penalización *L1* selecciona de manera natural un subconjunto parsimonioso de variables al asignar coeficientes exactamente iguales a cero a predictores con baja capacidad explicativa. Adicionalmente, en modelos computacionalmente costosos resulta además ventajoso trabajar con un número reducido de variables. Por ello, entre las variables seleccionadas por Lasso se eligieron aquellas con coeficientes de mayor magnitud en valor absoluto, generando el conjunto final de variables empleadas para el modelamiento predictivo.

Las descriptivas muestran que la estructura espacial del conjunto de entrenamiento está fuertemente concentrada en unas pocas localidades. Como se observa en el Cuadro 2, más del 55 % de las observaciones provienen de Usaquén, 13 % de Suba y 5 % de Teusaquillo, mientras que la mayoría del resto se distribuye en el resto de la ciudad. Esta concentración geográfica implica que el set de entrenamiento contiene información muy similar a la utilizada posteriormente en el conjunto de prueba, lo que anticipa un grado importante de continuidad espacial entre ambos.

La comparación entre train y test confirma esa cercanía. El Cuadro 5 muestra que las viviendas de Chapinero tienden a tener menos habitaciones y baños y a estar más cerca de equipamientos urbanos como bibliotecas, museos, colegios y estaciones de TransMilenio. Aunque estas brechas son estadísticamente significativas, todas las magnitudes son consistentes con la localización de Chapinero, donde la densidad y accesibilidad a servicios son mayores y las viviendas suelen ser más compactas que en otras zonas del norte de la ciudad. Además, en magnitudes, las diferencias de baños o cercanía a medios de transporte no son tan grandes entre ambas muestras, demostrando que ambas podrían tener características similares en amenidades fundamentales.

Un patrón similar aparece al examinar las variables categóricas (Cuadro 6). Aunque la proporción de apartamentos aumenta notablemente en el conjunto de prueba, la frecuencia de amenidades como zonas húmedas, walking closet, jacuzzi, piscina, balcón, gimnasio o terraza se mantiene en niveles muy cercanos a los del train. Esto sugiere que, en términos de características arquitectónicas y de equipamiento, el conjunto de prueba no introduce un cambio sustancial en la distribución observada durante el entrenamiento. Las diferencias más marcadas se presentan en la disponibilidad de zonas verdes y de parqueadero cubierto, aunque incluso estas variaciones permanecen dentro de rangos coherentes con la concentración espacial del conjunto de prueba.

La Figura 1 muestra el histograma de precios en el conjunto de entrenamiento, donde se observa que la distribución de precios de las casas presenta una cola más pesada que la de los apartamentos. La Figura 2 presenta la distribución espacial de los datos, revelando una concentración clara de propiedades de mayor valor a lo largo del corredor oriental de la ciudad, especialmente cerca de los cerros, mientras que los valores más bajos se distribuyen hacia el occidente. Este patrón espacial es consistente entre tipos de vivienda y refleja la segmentación histórica del mercado inmobiliario bogotano: zonas con mayor accesibilidad, oferta cultural y percepción de seguridad albergan precios más altos, independientemente de si se trata de casas o apartamentos. Además, la distribución densa y entremezclada de colores indica que el conjunto de entrenamiento captura bien esta heterogeneidad

espacial, brindando a los modelos suficientes ejemplos locales para aprender las variaciones de precio dentro de cada zona.

3. Modelo y Resultados

Para predecir la función de precios de propiedades residenciales en Bogotá, siguiendo a Rosen (1974), se estimó el precio de cada propiedad como una función de sus características, amenidades, atributos del barrio y espaciales. Nuestro modelo con mejor desempeño en el score público de Kaggle emplea una arquitectura de red neuronal de una sola capa oculta con 20 nodos, incluyendo las 17 variables elegidas con la regularización tipo Lasso.

$$P_i = f(\text{Habitaciones}_i, \text{Dist. Biblioteca}_i, \text{Dist. Colegio}_i, \text{Dist. Museo}_i, \text{Dist. TM}_i, \\ \text{TipoPropiedad}_i, \text{Baños}_i, \text{Parq. Cubierto}_i, \text{ZonaHúmeda}_i, \text{WalkingCloset}_i, \text{ZonaVerde}_i, \\ \text{Chimenea}_i, \text{Jacuzzi}_i, \text{Piscina}_i, \text{Balcón}_i, \text{Gimnasio}_i, \text{Parq. Comunal}_i, \text{Terraza}_i) + u_i$$

Para entender el desempeño de nuestro modelo, es útil revisar brevemente cómo opera una red neuronal con una sola capa oculta. Las redes neuronales de una sola capa oculta corresponden a un modelo de regresión no lineal capaz de aproximar funciones complejas mediante combinaciones sucesivas de transformaciones lineales y funciones de activación. En nuestro caso, empleamos una arquitectura compuesta por una capa de entrada, una única capa oculta con **20 neuronas** y una capa de salida con activación lineal para producir la predicción del precio. Cada neurona oculta transforma las covariables mediante una función sigmoide,

$$h_j = \sigma \left(\sum_{k=1}^p w_{jk} x_k + b_j \right),$$

donde $\sigma(z) = \frac{1}{1+e^{-z}}$, los x_k representan las características del inmueble y su entorno, y w_{jk} y b_j son parámetros aprendidos durante el entrenamiento. La salida del modelo se calcula como una combinación lineal de estas activaciones:

$$\hat{y} = \beta_0 + \sum_{j=1}^{20} \beta_j h_j,$$

lo que permite capturar relaciones no lineales e interacciones entre variables sin especificarlas manualmente. El entrenamiento se realiza mediante descenso de gradiente, ajustando los pesos para minimizar el error de predicción, mientras que técnicas de regularización como *weight decay* ayudan a prevenir sobreajuste. A pesar de su simplicidad, esta arquitectura resulta suficientemente flexible para modelar patrones complejos en los precios de vivienda.

3.1. Ajuste de Hiperparámetros

Para entrenar el modelo se empleó un parámetro de decaimiento de pesos $\lambda = 0,010$ para la regularización, un máximo de 500 iteraciones y un algoritmo de backpropagation para la estimación de los pesos, con validación de retención (80-20). El criterio fundamental para la selección de estos valores fue optimizar el tiempo de estimación de la Red dada la capacidad de procesamiento de nuestros computadores y también las recomendaciones usuales que la literatura indica para este tipo de arquitectura de modelos (Goodfellow et al. (2016); Bishop (2006)).

Asimismo, el tamaño de la red fue intencional. Al entrenar arquitecturas más grandes se sobreajustaban las predicciones a los datos de entrenamiento, generalizando peor tanto en la validación,

como en el resultados de la competencia de Kaggle. El decaimiento moderado de pesos ($\lambda = 0,01$) proporcionó suficiente regularización para prevenir el sobreajuste mientras mantenía la capacidad predictiva del modelo.

3.2. Comparación con el resto de los modelos

En el cuadro 7 se resumen los otros modelos entrenados para predecir el precio de las viviendas. Se estimó un conjunto diverso de nueve modelos adicionales que representan enfoques lineales, no lineales y de *ensemble learning*. En particular, un modelo Elastic Net con un $\alpha = 0,1$, tres especificaciones de XGBoost que variaron en complejidad de la grilla y en el tipo de validación, y dos Random Forest alternando entre validación cruzada espacial y tradicional. Finalmente, se incluyeron tres versiones del SuperLearner combinando diferentes ponderaciones de XGBoost, Random Forest, Elastic Net y redes neuronales. Este conjunto de modelos permite explorar una amplia gama de estructuras predictivas y comparar cómo distintos supuestos sobre la forma funcional, la complejidad y la regularización afectan la precisión en la predicción del precio de vivienda.

Una posible hipótesis para explicar por qué la red neuronal supera el desempeño de Random Forest es que la función subyacente que relaciona las características de la vivienda con su precio podría depender de relaciones suaves y no lineales, así como de interacciones continuas entre atributos estructurales, ubicación y amenidades. Mientras que Random Forest aproxima estas relaciones mediante particiones discretas del espacio —lo que genera predicciones en forma de “escalones”— la red neuronal produce funciones más continuas gracias a la activación sigmoide, lo que podría capturar mejor variaciones graduales en variables geoespaciales o en la combinación de amenidades. Además, si existe coocurrencia fuerte o multicolinealidad entre dummies (algo frecuente en características de inmuebles), la red puede sintetizar estos patrones mediante combinaciones ponderadas de los inputs, evitando la fragmentación generada por splits binarios. Finalmente, la presencia de regularización mediante weight decay suaviza aún más la función estimada y reduce el riesgo de sobreajuste, lo cual podría contribuir a que la red neuronal generalice mejor que el Random Forest en este contexto.

De manera complementaria, también es posible plantear una hipótesis sobre por qué la red neuronal supera a XGBoost. Aunque este último es un método altamente flexible y capaz de capturar interacciones complejas mediante la suma de múltiples árboles, su representación sigue siendo una combinación de funciones por tramos generadas a partir de divisiones discretas en el espacio de covariables. Cuando la relación entre las características del inmueble y el precio es más bien suave y continua, la estructura aditiva de árboles puede producir una función demasiado fragmentada, especialmente si la profundidad, la tasa de aprendizaje o el parámetro *min.child.weight* no se ajustan con precisión. Estas particiones pueden amplificarse en presencia de covariables correlacionadas o geoespaciales, dando lugar a predicciones más irregulares y sensibles a patrones locales. En contraste, la red neuronal combina las covariables a través de transformaciones suavizadas y regularizadas, lo cual, junto con el uso de *weight decay*, favorece una función estimada más estable y con menor varianza

Por otro lado, un comentario adicional acerca de los XG Boost, el modelo con grilla moderada (tuning hasta 1000 árboles) superó tanto al de grilla más grande (hasta 2000 árboles) como al de grilla más conservadora (hasta 500 árboles). Una posible explicación es que la configuración moderada alcanzó un equilibrio más adecuado entre complejidad y regularización: combinó una profundidad intermedia (5), un número razonable de árboles (941) y una tasa de aprendizaje relativamente alta (0.262), lo que permitió capturar patrones relevantes sin sobreajustarse. En contraste, la grilla más grande (profundidad 6, 1,584 árboles y learning rate 0.17) probablemente produjo una función demasiado fragmentada y sensible a patrones locales, especialmente cuando el número de árboles crece más rápido que la capacidad de regularización. Por otro lado, el modelo más conservador terminó fuera del top-10, lo que sugiere que, si bien evitó sobreajuste, su combinación de tasa de aprendizaje baja y restricciones estrictas en el crecimiento del árbol fue insuficiente para capturar la complejidad

presente en los precios de vivienda. Bajo esta hipótesis, la grilla moderada resultó ser la más eficiente al balancear flexibilidad y estabilidad en la predicción.

Finalmente, aunque el SuperLearner incluía dentro de su librería las versiones óptimas del Random Forest, los mejores XGBoost, el Elastic Net ajustado e incluso la red neuronal con mejor desempeño, ninguno de sus ensamblajes logró superar a los modelos individuales. En los distintos escenarios de validación, el meta-learner asignó 64.2 % del peso al Random Forest, 35.7 % a XGBoost y 0.00 % tanto a la red neuronal como al Elastic Net, lo que indica que privilegió la combinación entre los modelos de árboles. Esto sugiere que, aunque el SuperLearner busca minimizar el error promedio, su efectividad depende menos del rendimiento aislado de cada modelo y más de la complementariedad entre los patrones de error. En este caso, varios modelos débiles (como Elastic Net o ciertas variantes conservadoras de XGBoost) aportaban poca información nueva, mientras que los modelos más fuertes compartían errores similares en segmentos del espacio de covariables, limitando las ganancias potenciales del ensamblaje.

Un aspecto crucial es que la red neuronal —pese a ser el mejor modelo individual— no fue seleccionada por el meta-learner. Esto puede deberse a que sus errores no eran lo suficientemente distintos de los generados por los modelos de árboles. El weight decay utilizado en su entrenamiento produce una función suavizada y estable, lo que puede generar residuales relativamente homogéneos y menos útiles para corregir los errores locales capturados por RF y XGBoost. En ese sentido, aunque la red neuronal explique bien la estructura global del precio, su patrón de error no aporta la variación marginal que el SuperLearner necesita para mejorar la mezcla, lo que finalmente lleva a que reciba un peso de cero.

En contraste, el hecho de que el SuperLearner asignara peso exclusivamente a Random Forest y XGBoost indica que estos algoritmos producen errores parcialmente desalineados entre sí, ofreciendo al meta-modelo la heterogeneidad necesaria para armar una combinación más estable. Aunque ambos se basan en árboles, difieren en su forma de construir particiones: Random Forest reduce varianza mediante múltiples árboles independientes con mtry aleatorio, mientras que XGBoost construye árboles secuenciales que ajustan residuales de manera más agresiva. Esta diferencia genera patrones de error lo suficientemente distintos como para que el SuperLearner los considere complementarios y, por tanto, útiles para ensamblar.

En conjunto, estos mecanismos explican por qué el SuperLearner produjo una función más estable pero menos precisa que los mejores modelos individuales. La redundancia entre varios modelos basados en árboles, la falta de complementariedad en los errores de la red neuronal y el aporte limitado de Elastic Net llevaron al meta-learner a priorizar estabilidad sobre ajuste fino. Esto se refleja en los resultados: ninguno de los SuperLearners logró ubicarse dentro del top 5 y, en varios casos, quedaron incluso fuera del top 7, mientras que la red neuronal, el Random Forest y los mejores XGBoost dominaron el ranking de desempeño.

3.3. Estrategias de validación

Para validar el desempeño del entrenamiento en el mejor modelo se emplearon tanto estrategias de validación cruzada convencional como validación espacial. Para la primera, se dividió la base de datos aleatoriamente entre una muestra para el entrenamiento (80 %, 30.915 observaciones) y otra para la validación (20 %, 7.729 observaciones). Para la validación cruzada espacial empleamos una clusterización k-means, con 6 clusters a los datos georeferenciados (latitud y longitud). Se asignaron 4 clusters para en entrenamiento y 2 geográficamente distintos para hacer la validación. La figura 3, en anexos, muestra su distribución geográfica.

Los criterios de evaluación del desempeño de la predicción (MAE, MAPE) muestran una brecha

sustancial del desempeño entre validación aleatoria y espacial (MAE aumentó 36 %) esto indica una fuerte autocorrelación espacial en los precios de las propiedades. Los modelos entrenados validación cruzada tradicional se benefician de tener propiedades cercanas tanto en conjuntos de entrenamiento como de validación, calculando métricas de validación infladas. Estos resultados se presentan en el cuadro 2.

Cuadro 1. Desempeño de Validación: División Aleatoria vs. Espacial para Red Neuronal

Método de Validación	MAE (millones COP)	MAPE (%)
Validación cruzada convencional	143	21.7
Validación cruzada espacial	195	26.3
Diferencia	+36 %	+21 %

Este mismo deterioro bajo validación espacial (en este caso con 5 folds) se observa también en los modelos de Random Forest, XGBoost y en el propio SuperLearner, tanto en validación interna como fuera de muestra. Una posible explicación es que estos algoritmos, al estar basados en particiones del espacio de covariables, tienden a capturar patrones locales muy específicos de las zonas donde entrenan; cuando las carpetas de validación se forman mezclando observaciones cercanas, el modelo aprovecha relaciones espaciales que no se mantienen cuando se evalúa en áreas distintas. En cambio, la validación espacial rompe por completo esa proximidad geográfica: obliga a predecir propiedades ubicadas en sectores donde el modelo no ha visto puntos vecinos, exponiendo su dependencia a la correlación espacial en los predictores y en el precio.

Aunque parezca contraintuitivo, el hecho de que la validación espacial presente un peor desempeño —incluso fuera de muestra— se vuelve más comprensible si recordamos que, según las estadísticas descriptivas, las viviendas no difieren sustancialmente entre sí y que, como muestra el Cuadro 3, la mayoría de observaciones provienen de localidades aledañas a Chapinero. Bajo estas condiciones, el modelo encuentra en el conjunto de entrenamiento propiedades muy similares a las del conjunto de prueba, lo que favorece la generalización dentro de Bogotá. La validación espacial, sin embargo, rompe deliberadamente esta continuidad geográfica e impide que el modelo se beneficie de patrones locales o idiosincrasias espaciales. Los resultados sugieren que existen observables y, especialmente, no observables que generan una fuerte cercanía estructural entre los datos de entrenamiento y los de prueba, de modo que el modelo funciona razonablemente bien dentro de la ciudad, pero no necesariamente en un escenario más amplio donde esa similitud espacial ya no está garantizada.

3.4. Importancia de las variables

El modelo de Random Forest (nuestro segundo mejor *score*) permite identificar qué variables aportan más información para explicar la variación en los precios de vivienda. En nuestro caso, las variables más importantes corresponden tanto a características estructurales del inmueble como a elementos de ubicación y amenidades. La figura 4 muestra las variables más importantes.

Entre las primeras, destacan baños, habitaciones y el tipo de propiedad, lo cual es intuitivo: la configuración interna de la vivienda determina en gran medida su valor de mercado, y diferencias entre apartamentos y casas generan estructuras de precios distintas. Las variables geoespaciales también ocupan un lugar central. Distancias a museos, a estaciones de TransMilenio, a colegios y a bibliotecas capturan patrones de accesibilidad y cercanía a equipamientos urbanos, factores especialmente relevantes en mercados altamente segmentados como el de Bogotá. En zonas como Chapinero, donde la densidad de servicios, transporte y actividades culturales es alta, pequeñas variaciones en proximidad pueden traducirse en diferencias significativas en el precio.

Finalmente, varias amenidades específicas —parqueadero cubierto, terraza, chimenea, walking closet, gimnasio, zona verde, piscina, jacuzzi, parqueadero comunal y zona húmeda— también muestran importancia, aunque más moderada. Esto es consistente con la lógica del mercado: estas características no determinan por sí solas el valor del inmueble, pero sí agregan diferenciación y capturan heterogeneidad dentro de segmentos similares, por lo que el modelo las utiliza para refinar predicciones en clústeres de viviendas con atributos parecidos.

En conjunto, la importancia asignada por el Random Forest refleja una jerarquía razonable: primero, atributos estructurales que afectan directamente la habitabilidad; luego, medidas de accesibilidad urbana y localización; y, en último lugar, amenidades que matizan el precio dentro de categorías ya definidas. Esta combinación sugiere que el modelo aprovecha tanto factores estructurales como espaciales y de estilo de vida para caracterizar adecuadamente el precio de la vivienda en Bogotá.

4. Conclusiones

Este trabajo desarrolló y comparó múltiples algoritmos de Machine learning para la predicción de precios de vivienda en la localidad de Chapinero en Bogotá. Los resultados obtenidos permiten extraer conclusiones tanto para la práctica de valoración automatizada de inmuebles como para la metodología econométrica aplicada en contextos espaciales.

1. **Lo simple a veces supera lo muy elaborado:** El mejor desempeño de la red neuronal simple puede atribuirse a varios factores. Por un lado, su capacidad para modelar relaciones suaves y continuas mediante funciones de activación sigmoide le permite capturar mejor los gradientes espaciales y las interacciones graduales entre amenidades que caracterizan al mercado inmobiliario de Bogotá. Al ser una arquitectura sencilla, logra ponderar mejor el trade off entre sobreajuste y varianza. Modelos con arquitecturas más elaboradas tendían al sobreajuste y a una generalización peor. A su vez, la regularización ($\lambda = 0,01$) previene también el sobreajuste que típicamente afecta a arquitecturas más profundas o con mayor número de parámetros. En contraste, los métodos basados en árboles generan funciones por tramos que pueden resultar demasiado fragmentadas cuando la relación real entre características y precio es fundamentalmente continua.
2. **La importancia de la validación cruzada espacial:** Un segundo hallazgo clave se relaciona con el papel de la autocorrelación espacial en los datos inmobiliarios. La validación cruzada espacial, implementada mediante partición geográfica con k-means, mostró que el error de predicción (MAE) aumenta en 36 % cuando el modelo debe generalizar a barrios geográficamente distintos de aquellos presentes en el entrenamiento. Este resultado coincide con la literatura en econometría espacial y evidencia que romper la cercanía geográfica reduce la capacidad predictiva al eliminar patrones locales que los modelos aprovechan. No obstante, en nuestro caso particular, las propiedades del conjunto de prueba están concentradas en Chapinero y son similares a gran parte de las observaciones del entrenamiento, lo que implica que la validación tradicional ofrece una estimación más realista del desempeño fuera de muestra en Kaggle, dado el grado de continuidad estructural y espacial dentro del norte de Bogotá.
3. **Ensamblaje de modelos no garantiza mejores resultados:** Los resultados evidencian que el ensamblaje de modelos mediante SuperLearner no garantiza mejoras sobre los mejores modelos individuales. A pesar de incluir las versiones óptimas de Random Forest, XGBoost, Elastic Net y redes neuronales, ninguno de los tres SuperLearners implementados logró posicionarse entre los cinco mejores modelos. El meta-aprendizaje asignó pesos exclusivamente a Random Forest (64.2 %) y XGBoost (35.7 %), descartando completamente la red neuronal y el Elastic Net. Este comportamiento sugiere que, aunque el SuperLearner busca minimizar el error de

validación, su efectividad depende críticamente de la complementariedad entre los patrones de error de los modelos base. Cuando varios modelos fuertes comparten errores similares, como probablemente ocurre, el ensamblaje puede priorizar estabilidad sobre precisión, resultando en predicciones más conservadoras pero menos ajustadas.

4. **La importancia de incorporar datos adicionales y características:** Desde una perspectiva metodológica, la incorporación de características y el procesamiento de variables textuales (como descripciones en los avisos) permitió incorporar amenidades y atributos cualitativos, mejorando notablemente la medición de variables clave como área y número de baños. Asimismo, la integración de capas geoespaciales desde Datos Abiertos Bogotá —incluyendo accesibilidad a equipamientos, criminalidad, infraestructura y características socioeconómicas— enriqueció sustancialmente el conjunto de predictores, permitiendo capturar dimensiones del valor de la vivienda que no pueden inferirse únicamente desde sus atributos físicos.
5. **Sobre la responsabilidad en el ejercicio profesional:** el caso de Zillow, ofrece una lección adicional sobre los riesgos asociados al uso inadecuado de modelos automatizados de valoración. El fracaso de su algoritmo de compra automatizada, que resultó en pérdidas superiores a 500 millones de dólares, subraya que incluso modelos predictivos con buen desempeño en validación pueden generar decisiones subóptimas si no se acompañan de una comprensión profunda del contexto institucional, las fricciones de mercado y las limitaciones inherentes a los datos observacionales. En contraste, en un ejercicio académico, donde el objetivo es minimizar el error de predicción en un conjunto de prueba predefinido, las aplicaciones prácticas en compra-venta de inmuebles requieren incorporar consideraciones sobre liquidez, costos de transacción, selección adversa y otros factores no capturados por los predictores habituales.

Finalmente, este trabajo muestra que las redes neuronales simples, debidamente regularizadas y entrenadas con un conjunto parsimonioso de variables bien construidas, constituyen una alternativa competitiva frente a métodos más complejos para la valoración automatizada de vivienda en contextos urbanos heterogéneos. La autocorrelación espacial es fenómeno relevante que debe considerarse explícitamente al diseñar estrategias de validación, aunque su impacto práctico depende de la distribución geográfica específica de los conjuntos de entrenamiento y prueba. Finalmente, el ensamblaje de modelos mediante SuperLearner, si bien conceptualmente atractivo, no garantiza mejoras sistemáticas cuando los modelos base presentan patrones de error poco complementarios. Investigaciones futuras podrían explorar arquitecturas más profundas con técnicas avanzadas de regularización, así como la incorporación explícita de dependencia espacial con el fin de capturar de manera más precisa la estructura geográfica de los mercados inmobiliarios.

5. Anexos

Cuadro 2. Distribución de observaciones por localidad en el conjunto de datos

Localidad	Frecuencia	Porcentaje	Acumulado
Antonio Nariño	298	0.77 %	0.77 %
Barrios Unidos	1,708	4.42 %	5.19 %
Bosa	28	0.07 %	5.26 %
Candelaria	179	0.46 %	5.73 %
Chapinero	3,690	9.55 %	15.28 %
Ciudad Bolívar	70	0.18 %	15.46 %
Engativá	1,831	4.74 %	20.20 %
Fontibón	1,842	4.77 %	24.97 %
Kennedy	1,517	3.93 %	28.90 %
Los Mártires	264	0.68 %	29.58 %
Puente Aranda	667	1.73 %	31.31 %
Rafael Uribe Uribe	177	0.46 %	31.77 %
San Cristóbal	69	0.18 %	31.94 %
Santa Fe	932	2.41 %	34.35 %
Suba	5,102	13.20 %	47.56 %
Teusaquillo	2,072	5.36 %	52.92 %
Tunjuelito	119	0.31 %	53.24 %
Usaquén	21,462	55.50 %	100.00 %
Total	38,644	100.00 %	100.00 %

Cuadro 3. Estadísticas descriptivas de las variables continuas en el conjunto de datos de entrenamiento

Variable	N	Mean	St. Dev.	Min	Max
Habitaciones	38,605	3.1	1.5	0	11
Distancia a biblioteca más cercana	38,605	592.5	321.7	4.7	1,873.9
Distancia a colegio más cercano	38,605	313.2	192.8	0.000	1,411.8
Distancia a museo más cercano	38,605	1,546.3	1,034.0	10.4	6,553.6
Distancia a Transmilenio más cercano	38,605	1,154.5	784.6	1.1	5,456.7
Baños	38,605	2.8	1.1	1	12

Cuadro 4. Estadísticas descriptivas de las variables continuas en el conjunto de datos de teste

Variable	N	Media	St. Dev.	Min	Max
Habitaciones	10,286	2.4	1.0	0	11
Distancia a biblioteca más cercana	10,286	404.4	219.3	7.9	1,598.2
Distancia a colegio más cercano	10,286	492.5	241.0	5.7	1,611.4
Distancia a museo más cercano	10,286	792.7	406.7	12.6	2,849.6
Distancia a Transmilenio más cercano	10,286	994.2	524.6	1.5	3,849.2
Baños	10,286	2.6	0.9	1	10

Cuadro 5. Diferencia de medias entre Train y Test con significancia estadística

Variable	Train	Test	Diferencia	p-value
Habitaciones	3.1	2.4	-0.7	< 0.0001***
Distancia a biblioteca más cercana	592.5	404.4	-188.1	< 0.0001***
Distancia a colegio más cercano	313.2	290.1	-23.1	< 0.0001***
Distancia a museo más cercano	1546.3	792.7	-753.6	< 0.0001***
Distancia a Transmilenio más cercano	1154.5	992.9	-161.6	< 0.0001***
Baños	2.8	2.6	-0.2	< 0.0001***

Cuadro 6. Frecuencia de variables categóricas (solo categoría = 1 para variables dicotómicas)

Variable	Categoría	Train (%)	Test (%)
property_type	Apartamento	75.5	97.3
property_type	Casa	24.5	2.7
parqueadero_cubierto	1	7.8	4.2
zona_humeda	1	0.4	0.3
walking_closet	1	15.3	19.7
zona_verde	1	7.0	2.8
chimenea	1	23.4	29.9
jacuzzi	1	2.7	2.4
piscina	1	5.9	5.2
balcon	1	20.5	20.6
gimnasio	1	21.5	22.5
parqueadero_comunal	1	1.0	1.2
terraza	1	29.9	32.0

Referencias

- Baur, K., Rosenfelder, M., and Lutz, B. (2023). Automated real estate valuation with machine learning models using property descriptions. *Expert Systems with Applications*, 213:119147. Available online 28 October 2022.
- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer, New York, NY.
- Corkery, M. and Gelles, D. (2021). Zillow quits home-flipping business after big losses. *The New York Times*. Publicado el 2 de noviembre de 2021.
- Goodfellow, I., Bengio, Y., and Courville, A. (2016). *Deep Learning*. MIT Press, Cambridge, MA.
- Hjort, A., Pensar, J., Scheel, I., and Sommervoll, D. E. (2022). House price prediction with gradient boosted trees under different loss functions. *Journal of Property Research*, 39(4):338–364.
- Ho, W. K., Tang, B.-S., and Wong, S. W. (2020). Predicting property prices with machine learning algorithms. *Journal of Property Research*.
- Mora-Garcia, R.-T., Cespedes-Lopez, M.-F., and Perez-Sanchez, V. R. (2022). Housing price prediction using machine learning algorithms in covid-19 times. *Land*, 11(11):2100.

Cuadro 7. Comparación con el resto de los modelos cargados y los resultados

Posición	Modelo	Arquitectura	MAE Kaggle
1	Red neuronal	1 capa oculta 20 nodos tasa de aprendizaje: 0.01 activación sigmoide Validación tradicional	215
2	Random Forest	mtry = 9 500 árboles nodesize = 2 Validación tradicional	219
3	XG Boost	mtry = 30 941 árboles tasa de aprendizaje: 0.262 min.child.weight: 3 Profundidad máxima: 5 gamma = 0.001 Tamaño submuestra: 0.964 Validación tradicional	229
4	XG Boost	mtry = 22 1584 árboles tasa de aprendizaje: 0.17 min.child.weight: 6 Profundidad máxima: 6 gamma = 0.003 Tamaño submuestra: 0.851 Validación tradicional	236
5	Random Forest	mtry = 6 200 árboles nodesize = 2 Validación espacial	239
6	XG Boost	mtry = 10 707 árboles tasa de aprendizaje: 0.02 min.child.weight: 18 Profundidad máxima: 7 gamma = 0.001 Validación espacial	240
7	Superlearner(4 versiones de cada algortimo incluyendo los 3 mejores)	Con los mejores XGB y RF: 35.7 % XGBOOST 64.2 % RF Validación tradicional	246
8	Super Learner	Con los mejores XGB y RF: 36 % XGBOOST 63 % RF 0.00 % Elastic Net y nnet Validación espacial	248
9	Super Learner	Con los mejores XGB y RF: 35.7 % XGBOOST 64.2 % RF 0.00 % Elastic Net y nnet Validación tradicional	248
10	Elastic Net	alpha = 0.1 lambda = 0.01	248

Nota: Los valores del MAE estan en millones de pesos colombianos.

Figura 1. Histograma de los precios en los datos de entrenamientos, en Mil Millones de COP.




Figura 2. Distribución de las observaciones en los datos de entrenamiento y de prueba. Precios están en Mil Millones de COP




Figura 3. Clusterización geográfica para validación cruzada espacial




Figura 4. Importancia de las Variables en el Modelos Ranfom Forest

