

Mejor Modelo: Random Forest

Equipo 03 — Catalina Leal, Lucas D. Carrillo, Lucas E. Veras

Big Data y Machine Learning — PS2

November 24, 2025

Descripción General del Mejor Modelo

Random Forest

Versión 1: Bagging (Hellinger)

- `num.trees` = 500
- `mtry` = 26 (todas las variables)
- `node.size` = 50
- `split.rule` = Hellinger
- Umbral $\tau^* = 0.522$ (max F1 en CV)

Versión 2: Selección de variables (Gini)

- `num.trees` = 1000
- `mtry` = 6
- `node.size` = 1
- `split.rule` = Gini
- Umbral $\tau^* = 0.340$ (max F1 en CV)

Kaggle (Public Leaderboard): F1 = 0.63 (ambos modelos)

Datos: Fuente

- Datos extraídos de **Properati** (competencia de Kaggle): 48.930 viviendas en Bogotá, con 17 variables (tamaño, características, ubicación, precio, texto).
- El conjunto *train* contiene 38.644 viviendas de toda la ciudad con precio.
- El conjunto *test* incluye 10.286 viviendas ubicadas solo en Chapinero, sin precio.
- Se añadieron variables geoespaciales de **Datos Abiertos Bogotá**: cercanía a equipamientos, estrato, avalúo catastral, criminalidad, densidad comercial.

Procesamiento: Variables de texto

- Se unificó el título y la descripción en un solo texto por aviso.
- Limpieza: minúsculas, eliminación de acentos, puntuación y espacios redundantes.
- Revisión manual para identificar patrones sobre amenities, tamaño y condiciones del inmueble.
- Se construyó un diccionario de **33 variables**:
 - 30 dicotómicas (amenities).
 - 3 numéricas (área, parqueaderos, baños).
- Extracción numérica usando expresiones regulares; se sumaron múltiples menciones.

Procesamiento: Imputación basada en texto

- Con información textual se imputaron valores faltantes de área y número de baños.
- Solo se imputaron faltantes cuando el texto permitía una estimación confiable.
- Para valores aún faltantes: imputación por promedio condicional usando:
 - barrio/UPZ, habitaciones, baños, estrato, tipo de propiedad.
- Áreas agrupadas en intervalos de 10 m² para evitar fragmentación.
- Este módulo mejoró medición de variables clave como área, baños y amenities.

Variables espaciales: Construcción

- Train y test unificados en un objeto `sf` usando coordenadas en WGS84 (EPSG 4326).
- Unión espacial con:
 - Localidades del distrito.
 - Sectores censales.
- Integración de capas temáticas:
 - Espacio público (localidad y UPZ).
 - Luminarias por UPZ.
 - Bibliotecas, museos, colegios, estaciones de TransMilenio.
- Se calcularon distancias geodésicas al equipamiento más cercano.

Variables espaciales: Información socioeconómica

- Se añadieron variables socioeconómicas y fiscales:
 - Recaudo predial por polígono correspondiente.
 - Estrato asignado por manzana más cercana.
- Delitos por localidad (2019, 2020, 2022):
 - Homicidios, lesiones, hurtos, delitos sexuales, violencia intrafamiliar.
- Todas las capas se reprojectaron, depuraron y renombraron para consistencia.
- La dimensión espacial permite capturar accesibilidad, entorno, seguridad y estructura socioeconómica.

Selección de variables

- Aunque se generaron muchas variables, usarlas todas aumenta riesgo de *overfitting*.
- Se aplicó un **modelo Lasso** para seleccionar predictores:
 - Penalización L1 elimina variables con bajo poder explicativo.
 - Reduce costos computacionales en modelos no lineales.
- Se seleccionaron las **17 variables** con coeficientes de mayor magnitud.

Estadísticas descriptivas: Train y Test

Table: Descriptivas (Train)

Variable	N	Mean	SD	Min	Max
Habitaciones	38,605	3.1	1.5	0	11
Dist. biblio	38,605	592.5	321.7	4.7	1,873.9
Dist. colegio	38,605	313.2	192.8	0.0	1,411.8
Dist. museo	38,605	1,546.3	1,034.0	10.4	6,553.6
Dist. TM	38,605	1,154.5	784.6	1.1	5,456.7
Baños	38,605	2.8	1.1	1	12

Table: Descriptivas (Test)

Variable	N	Media	SD	Min	Max
Habitaciones	10,286	2.4	1.0	0	11
Dist. biblio	10,286	404.4	219.3	7.9	1,598.2
Dist. colegio	10,286	492.5	241.0	5.7	1,611.4
Dist. museo	10,286	792.7	406.7	12.6	2,849.6
Dist. TM	10,286	994.2	524.6	1.5	3,849.2
Baños	10,286	2.6	0.9	1	10

Frecuencia de variables categóricas

Table: Frecuencia de variables categóricas (solo categoría = 1 en dicotómicas)

Variable	Categoría	Train (%)	Test (%)
property_type	Apartamento	75.5	97.3
property_type	Casa	24.5	2.7
parqueadero_cubierto	1	7.8	4.2
zona_humeda	1	0.4	0.3
walking_closet	1	15.3	19.7
zona_verde	1	7.0	2.8
chimenea	1	23.4	29.9
jacuzzi	1	2.7	2.4
piscina	1	5.9	5.2
balcon	1	20.5	20.6
gimnasio	1	21.5	22.5
parqueadero_comunal	1	1.0	1.2
terrazza	1	29.9	32.0

Distribución de las Observaciones




Figure: Distribución espacial de las observaciones

Histograma de los Precios




Figure: Histograma de los precios en los datos de entrenamiento. Mil Millones de COP