

Comparación entre modelos

Catalina Leal Rojas, Lucas Daniel Carrillo Aguirre, Lucas Eduardo
Veras Costa, Mateo Hernández

November 25, 2025

Resumen del mejor modelo

Especificación del modelo

$$P_i = f(\text{Habitaciones}_i, \text{Dist. Biblioteca}_i, \text{Dist. Colegio}_i, \text{Dist. Museo}_i, \text{Dist. TM}_i, \\ \text{TipoPropiedad}_i, \text{Baños}_i, \text{Parq. Cubierto}_i, \text{ZonaHúmeda}_i, \text{WalkingCloset}_i, \\ \text{ZonaVerde}_i, \text{Chimenea}_i, \text{Jacuzzi}_i, \text{Piscina}_i, \text{Balcón}_i, \\ \text{Gimnasio}_i, \text{Parq. Comunal}_i, \text{Terraza}_i) + u_i$$

Arquitectura

- Kaggle Score: COP \$ 215 mm
- Red neuronal con una capa oculta y 20 nodos
- Activación sigmoide Tasa de decaimiento $\lambda = 0.001$
- 17 variables seleccionadas con Lasso

Top 10 modelos

- 1 Red Neuronal de una sola capa (215 millones)
- 2 Random Forest (validación tradicional) (219 millones)
- 3 XGBoost (validación tradicional, grilla moderada) (229 millones)
- 4 XGBoost (validación tradicional, grilla grande) (236 millones)
- 5 Random Forest (validación espacial) (239 millones)
- 6 XGBoost (validación espacial, grilla moderada) (240 millones)
- 7 SuperLearner (validación tradicional, muchos modelos) (246 millones)
- 8 SuperLearner (validación espacial, solo mejores modelos) (248 millones)
- 9 SuperLearner (validación tradicional, solo mejores modelos) (248 millones)
- 10 Elastic Net (validación tradicional) (248 millones)

Elementos en común de todos los modelos

- Nos quedamos con 17 variables de 54 elegidas por medio de un modelo Lasso.

$$P_i = f(\text{Habitaciones}_i, \text{Dist.Biblioteca}_i, \text{Dist.Colegio}_i, \text{Dist.Museo}_i, \text{Dist.TM}_i, \text{TipoPropiedad}_i, \text{Baños}_i, \text{Parq.Cubierto}_i, \text{ZonaHúmeda}_i, \text{WalkingCloset}_i, \text{ZonaVerde}_i, \text{Chimenea}_i, \text{Jacuzzi}_i, \text{Piscina}_i, \text{Balcón}_i, \text{Gimnasio}_i, \text{Parq. Comunal}_i, \text{Terraza}_i) + u_i$$

- Pasamos los precios a logaritmo y redondeamos el precio a 100miles
- Para ambos tipos de validación se usaron 5 *folds*

Random Forest (219 y 239 millones)

Hiperparámetro	Grilla Explorada	Valor Final (vct)	Valor final (vce)
Número de árboles	{200, 500}	500	200
Número de variables por split	{3, 6 ,9}	9	6
Tamaño mín nodo terminal	{2, 5}	2	2

Table: Grilla de hiperparámetros evaluados y valores seleccionados para los modelos Random Forest.

Random Forest (219 y 239 millones)

- La red neuronal puede capturar relaciones **suaves y no lineales** entre las variables, mientras que Random Forest depende de particiones abruptas del espacio.
- El mercado inmobiliario de Bogotá muestra **gradientes continuos de precio** (ubicación, accesibilidad, amenidades), mejor representados por una función suave como la NN.
- La capa oculta con 20 neuronas permitió una **mayor flexibilidad** sin sobreajustar, debido al uso de *weight decay*.
- Random Forest tiende a **sobreajustarse a patrones locales** y micro-segmentaciones espaciales, lo que reduce su capacidad de generalizar fuera de zonas densamente representadas.
- A pesar de no tener tuning, la NN encontró una **estructura estable y robusta** que superó sistemáticamente a RF en MAE.

Validación cruzada espacial vs Validación cruzada tradicional

- La validación espacial rompe la **cercanía geográfica**, aumentando el error al obligar al modelo a predecir en zonas sin puntos vecinos.
- Los modelos basados en árboles pierden su ventaja porque dependen de **micro-patrones locales** muy específicos.
- El test de Kaggle (Chapinero) es similar al train que proviene de **localidades vecinas**, por lo que la validación tradicional refleja mejor este escenario.
- La validación espacial mostró peor desempeño (fuera y dentro de muestra), pero esto se debe a la **continuidad espacial real** dentro del norte de Bogotá.

XGBOOST (229 y 240 millones)

- Se utilizó el comando *Latin Hypercube Sampling* con 30 modelos: distribuye inteligentemente puntos en el espacio de hiperparámetros para cubrirlo de manera eficiente.

Hiperparámetro	Grilla Explorada	Valor Final (vct)	Valor final (vce)
Tasa de aprendizaje	$\log(10^{-3}, 0)$	0.26	0.02
Número de variables por split	(5, 40)	30	10
Número de árboles	(200, 1000)	941	707
Profundidad máxima	(2, 8)	5	7
Peso mínimo por nodo	(2, 20)	3	18
Gamma (mínimo loss para split)	$\log(10^{-3}, 10)$	0.001	0.001

Table: Grilla de hiperparámetros evaluados y valores seleccionados para los modelos XGBOOST de grilla moderada

XGBOOST (236 millones)

- Se utilizó el comando *Latin Hypercube Sampling* con 50 modelos: distribuye inteligentemente puntos en el espacio de hiperparámetros para cubrirlo de manera eficiente.

Hiperparámetro	Grilla Explorada	Valor Final (vct)
Tasa de aprendizaje	$\log(10^{-3}, 0)$	0.17
Número de variables por split	(5, 50)	22
Número de árboles	(200, 2000)	1584
Profundidad máxima	(2, 10)	6
Peso mínimo por nodo	(2, 20)	6
Gamma (mínimo loss para split)	$\log(10^{-3}, 10)$	0.003

Table: Grilla de hiperparámetros evaluados y valores seleccionados para el modelo XGBOOST de grilla amplia

- Similar a lo mencionado en Random Forest, XGBoost aprende mediante particiones secuenciales, lo que produce **fronteras abruptas** que no representan bien gradientes suaves de precio. Mientras que la red neuronal captura **transiciones continuas** en ubicación, accesibilidad y amenidades, típicas del mercado de Bogotá.
- El *weight decay* estabilizó la NN evitando sobreajuste, mientras que XGBoost es más propenso a **memorizar patrones locales**.
- El XGBoost con grillas más complejas no mejoró: **hiperparámetros agresivos** aumentaron ruido sin capturar patrones nuevos.

Superlearners (246, 248 y 248 millones)

- 2 solamente incluyendo la red neuronal ganadora, el mejor Random Forest, el mejor XGBOOST y el mejor Elastic Net. La diferencia fue el tipo de validación: espacial y tradicional.
- Un modelo que incluyó los mejores modelos más 3 versiones adicionales de cada uno. Para cada modelo se agregó un modelo conservador, uno moderado y uno exhaustivo.
- **Los tres modelos quedaron con pesos de 0.35 para el mejor XGBOOST, 0.64 para el mejor RF y 0.00 para el resto de algoritmos**

Superlearners (246, 248 y 248 millones)

- El SuperLearner priorizó modelos basados en árboles (RF y XGB), pero estos comparten **errores espaciales** muy similares.
- La red neuronal, aunque era la más precisa individualmente, tenía **residuales poco complementarios** para el meta-learner.
- El SuperLearner terminó favoreciendo estabilidad sobre precisión, mientras que la NN ofrecía **mejor ajuste fino** en el rango de precios relevante.
- Ningún ensamblaje logró igualar a la NN porque no existía suficiente **complementariedad de errores** entre los modelos base.

Elastic Net (248 millones)

- $\alpha = 0.1$
- $\lambda = 0.01$
- El Elastic Net impone una **estructura lineal**, lo que limita su capacidad para capturar las relaciones no lineales presentes en los precios de vivienda.
- El mercado inmobiliario muestra **interacciones complejas** entre ubicación, amenidades y características estructurales, que un modelo penalizado lineal no puede representar adecuadamente.
- Aunque útil para reducir variables y manejar colinealidad, la penalización L1/L2 **suaviza demasiado** la relación entre predictores y precio.
- El SuperLearner le asignó un peso de 0.00%, indicando que sus errores eran **poco informativos** y no aportaban complementariedad a los ensamblajes.

Los que quedaron por fuera del top

- CART
- Modelo lineal
- Red Neuronal compleja
- XGBOOST con grilla pequeña

Conclusiones

- El análisis mostró que la estructura del mercado inmobiliario del norte de Bogotá permite capturar patrones estables con modelos flexibles pero no necesariamente complejos.
- La **red neuronal de una sola capa** (20 neuronas, sin tuning) fue el modelo con mejor desempeño, superando a Random Forest, XGBoost y SuperLearner.
- Resultado clave: **modelos simples pueden ganar** cuando los datos presentan continuidad espacial y relaciones suaves entre covariables y precio.
- La validación espacial reveló limitaciones para extrapolar a zonas nuevas, por lo que recomendamos usarla siempre que se busque generalizar más allá del área estudiada.
- Recomendación general: combinar selección de variables, modelos flexibles y validación adecuada según el objetivo —predicción local vs. generalización amplia.